阶段性技术总结

四川麻将血战到底 AI | 规则引擎 • 状态编码 • MLP • DAgger • PPO | 2026 年 10 月

摘要

本报告梳理仓库当前可运行的规则引擎、训练脚本、数据文件、模型检查点与测试，说明模块调用关系和训练/评测口径。规则引擎支持四人 108 张牌、定缺、可选换三张、碰杠、抢杠胡、一炮多响和血战续打；流局赔偿仍是简化实现。模型只负责出牌和响应两类决策，其余动作由规则策略处理。仓库附带 5000 局规则 AI 采样数据和 600 局 DAgger 数据。已有实验记录中，DAgger 模型相对规则基线的每座得分差为 -0.69，优于纯行为克隆的 -1.13；小规模 PPO 未带来进一步提升。

1 项目文件与实现边界

图 1 将实际代码节点展开到文件级。Game 是规则真值；决策器读取合法动作并调用编码/网络，最终由 Game.step() 推进状态。图中未把规划中的服务层画成已交付系统。

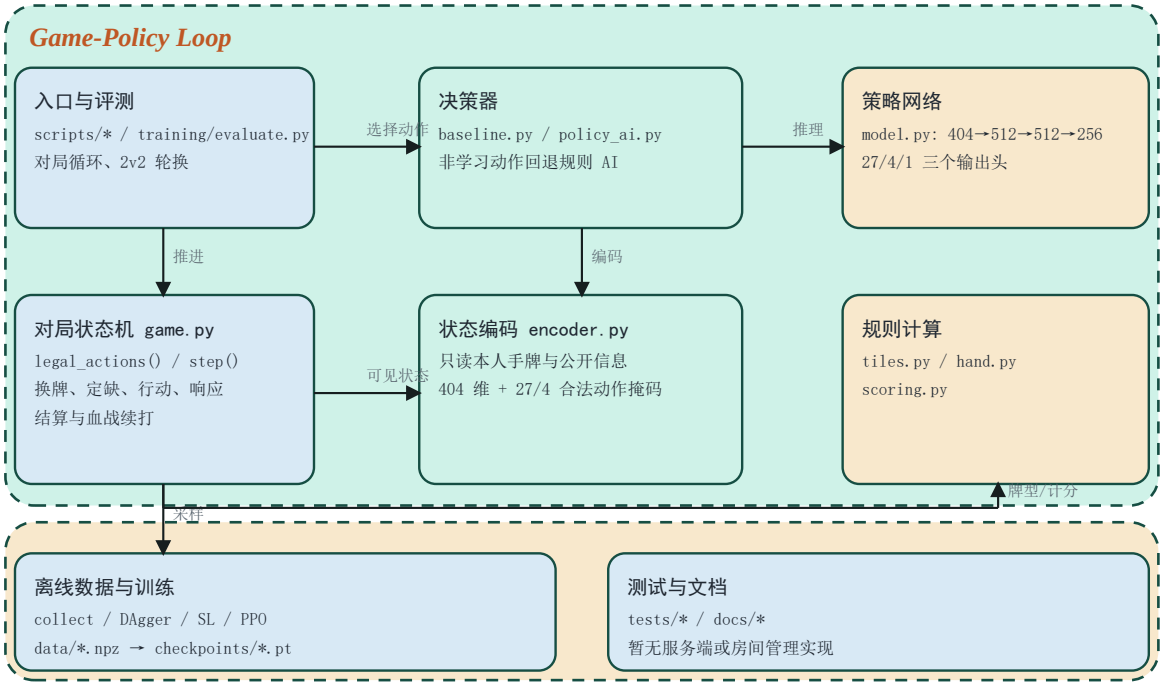


图 1-1 现有实现的模块与调用关系（箭头表示调用或数据传递）

表 1-1 项目主要文件及职责

目录 / 文件	职责与产物
src/sichuan_mahjong/	tiles.py 牌编码；hand.py 向听/胡牌；scoring.py 计分；game.py 状态机；baseline.py 规则策略；encoder.py 特征和合法动作掩码。
training/	collect.py 监督样本；collect_batch.py 分片合并；dagger.py 重标；train_sl.py 行为克隆；ppo.py 强化学习；model.py 网络；policy_ai.py 推理；evaluate.py 对基线评测。
scripts/ 与 tests/	模拟、基准、评测和测试入口；测试覆盖规则、编码、训练与 PPO 冒烟。
data/ 与 checkpoints/	sl.npz、dagger.npz；sl_policy.pt、sl_dagger.pt、ppo_policy.pt。二进制产物不等同于训练日志。
docs/ 与 paper/	设计、API、实验记录、服务规划；本报告及构建脚本。M3_SERVING.md 是方案，尚无服务端实现。

2 规则引擎与信息边界

Game 的核心接口为 legal_actions()、step(action)、scores() 和 view(seat)。流程包含换三张、定缺、回合行动、弃牌响应与终局；合法动作由引擎生成，计分由 scoring.py 处理。玩家胡牌后退出，其他玩家继续；同一弃牌可被多家胡。流局查花猪/查大叫为可配置的简化结算，连庄与多局积分未实现。

编码器只读取本人的暗牌，以及四家牌河、副露、定缺、分数、胡牌标记等公开状态；不会读取对手暗牌。它输出 404 维浮点特征，出牌掩码 27 位，响应掩码 4 位。响应动作次序固定为胡、碰、明杠、过。



编码不读取对手暗牌；D 和 C 由 Game.legal_actions() 另行生成，不占 404 维。

图 2-1 状态编码的偏移、归一化和独立合法动作掩码

状态编码器采用显式特征拼接。设 i 为牌种索引，s 为座位，h、q、m 分别为本人手牌计数、四家弃牌计数与明副露计数。输出由 14 个区段按固定顺序拼接，总维数为 404；合法动作掩码 D、C 不参与拼接。

$$x = [h/4, p, g, q/4, m/4, u, w/55, f/50, z, d, r, t, v, n] \in R^{404} \tag{2-1}$$

式 (2-1) 中 p、g 为本人碰/杠掩码，u 为四座定缺独热编码，w 为牌墙剩余张数，f 为四座分数，z 为已胡标记，d 为刚摸牌独热向量，r 为响应阶段标记，t 为待响应牌独热向量，v 为弃牌者相对座位编码，n 为每种牌的剩余张数。

$$n_i = \max\{0, 4 - h_i - \sum_{s=0}^{3} (q_{s,i} + m_{s,i})\}/4 \tag{2-2}$$

式 (2-2) 的剩余张数只扣除本人手牌和全部可见弃牌、副露，不涉及对手暗牌。D 和 C 则由规则引擎针对当前局面独立生成：

$$D_i = 1[(\text{DISCARD}, i) \in A_{legal}] \tag{2-3}$$

$$C_k = 1[K_k \in \text{kind}(A_{legal})] \tag{2-4}$$

式（2-3）的二元组表示出牌动作及牌种。$\text{kind}(A_{legal})$ 表示合法动作的类型集合，K 按胡、碰、明杠、过排序。指示函数 $1[\cdot]$ 在条件成立时取 1，否则取 0。特征段的精确偏移见图 2-1，归一化汇总见表 2-1。

表 2-1 状态编码特征及归一化

404 维特征段	维度	代码中的值
本人手牌 / 碰 / 杠	27 + 27 + 27	张数 / 4；两个副露布尔掩码
四家弃牌 / 副露	108 + 108	按座位顺序，每家 27 维，张数 / 4
定缺 / 牌墙 / 分数 / 已胡	12 + 1 + 4 + 4	one-hot；剩余 / 55；分数 / 50；布尔标记
刚摸牌 / 响应标记 / 待响应牌 / 相对座位	27 + 1 + 27 + 4	one-hot 与阶段标记
可见牌以外的剩余张数	27	max(0, 4 − 可见数) / 4

3 网络与决策路径

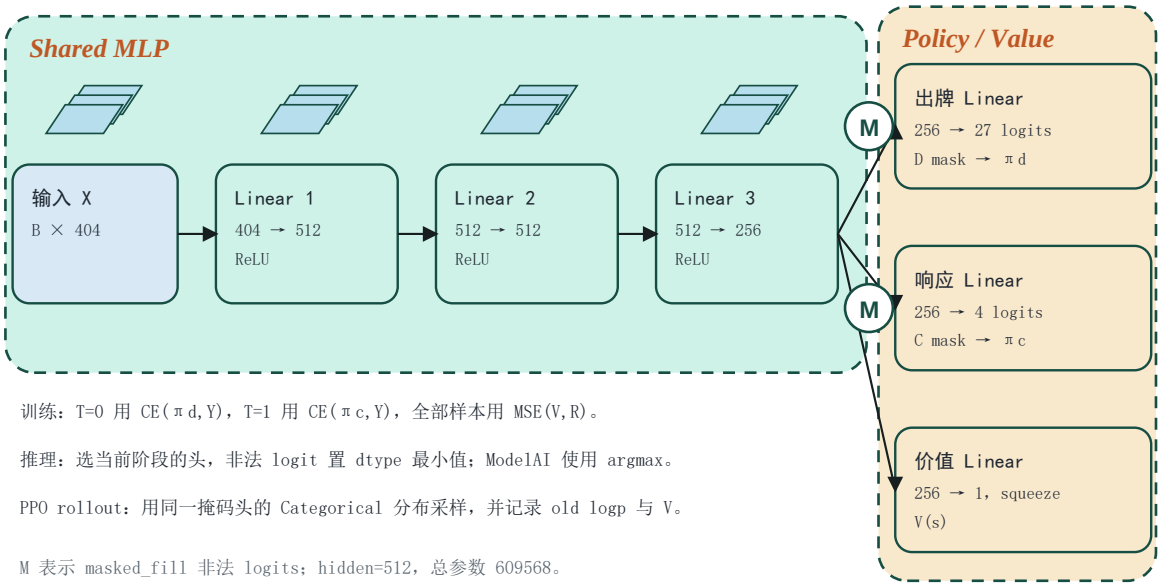


图 3-1 共享 MLP、掩码动作头与价值头

PolicyValueNet 使用 404→512→512→256 的三层 ReLU 主干，输出 27 维出牌 logits、4 维响应 logits 和 1 维价值。非法动作由掩码屏蔽。ModelAI 只在出牌或响应阶段调用动作头；定缺、换牌、自摸、暗杠和补杠交给 BaselineAI。

现有网络没有独立的序列解码器。共享表示通过出牌头和响应头转为动作分数，经过合法动作掩码后完成选择。其逐层映射为：

$$h^{(0)} = x,\ \ h^{(l)} = \mathrm{ReLU}(W^{(l)}h^{(l-1)} + b^{(l)}),\ \ l = 1, 2, 3 \tag{3-1}$$

$$z_D = W_D h^{(3)} + b_D,\ \ z_C = W_C h^{(3)} + b_C,\ \ V = W_V h^{(3)} + b_V \tag{3-2}$$

$$z^{\mathrm{mask}}_j = M_j z_j + (1 - M_j)\,\min(\mathrm{dtype}),\ \ a^* = \mathrm{argmax}_j\, z^{\mathrm{mask}}_j \tag{3-3}$$

式 (3-3) 中 M 在出牌阶段取 D，在响应阶段取 C；min(dtype) 是浮点类型的最小有限值。推理使用 argmax，PPO 采样则从掩码后的 logits 构造 Categorical 分布。价值头不参与推理动作选择。

表 3-1 网络层形状与参数量

层 / 输出	形状	参数量	参与的决策或损失
共享层 1	404 → 512 + ReLU	207360	全部样本
共享层 2	512 → 512 + ReLU	262656	全部样本
共享层 3	512 → 256 + ReLU	131328	全部样本
出牌头	256 → 27	6939	T=0 的合法出牌与交叉熵
响应头	256 → 4	1028	T=1 的胡/碰/明杠/过与交叉熵
价值头	256 → 1	257	终局分/50 的回归；PPO 的基线

3.1 为什么采用共享 MLP

当前输入是人工定义的 404 维定长向量，已把牌种计数、公开动作、阶段和相对座位编码成数值，不包含完整出牌事件序列。三层 MLP 可以直接消费这种异质特征；共享主干让出牌、响应和价值预测复用同一局面表示。检查点中的 hidden=512，对应 609568 个参数。27/4 位掩码由规则引擎生成，模型只需在合法候选中排序；这也让监督学习和 PPO 共用同一个网络与动作接口。

表 3-2 候选模型与当前选型依据

候选方法	可能的优势	本项目当前的取舍
共享 MLP（三头）	适配定长特征；参数量较小；训练/推理接口简单。	作为可复现基线，容易接入 BC、DAgger 和 PPO；不能自动学习长事件序列。
CNN / 牌面卷积	可利用同花色相邻牌的局部结构。	现有 404 维含分数、座位和阶段等异质块；直接卷积缺少统一的局部邻接关系，需另设计输入。
Transformer / 序列模型	可建模弃牌和行动的先后顺序及长程依赖。	当前编码只保留按牌种聚合的牌河计数；训练文件没有事件序列，改用序列模型需重做数据采集。
搜索 / 蒙特卡洛规划	可显式评估多步行动后果。	四人不完全信息需为未知手牌建模并多次模拟；现有工程尚无信念状态或批量搜索框架。

选型因此是当前数据形态、训练规模和工程复杂度下的基线选择，而不是已验证的最优架构。仓库没有 MLP 与 CNN、Transformer 或搜索模型在相同数据和种子下的对照实验，不能声称 MLP 的实战强度或延迟已优于这些方法。后续若保存逐步行动历史，可以再测试序列模型；若需更强规划能力，应先建立未知手牌采样和多模型对照评测。

4 数据和训练路径

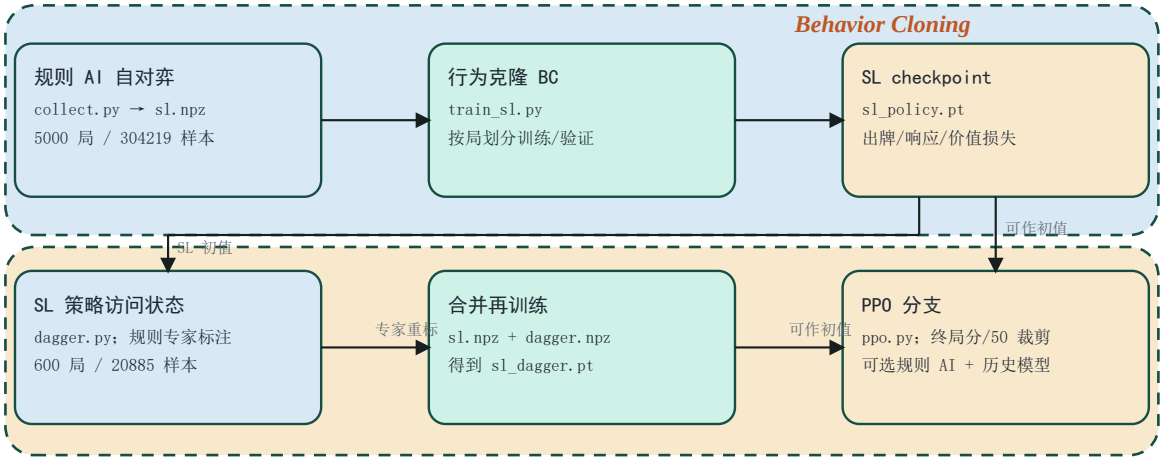


图 4-1 行为克隆、DAgger 与 PPO 的数据依赖和检查点

sl.npz 实测为 304219 条、X 为 (304219,404)；dagger.npz 为 20885 条、X 为 (20885,404)。两者均包含 D/C 合法动作掩码、Y 动作标签、T 动作类型、R 终局分数/50、G 局号和 S 座位。监督训练按局号分割训练/验证，避免同一局样本跨集合。只保留至少有两个合法响应的响应点。

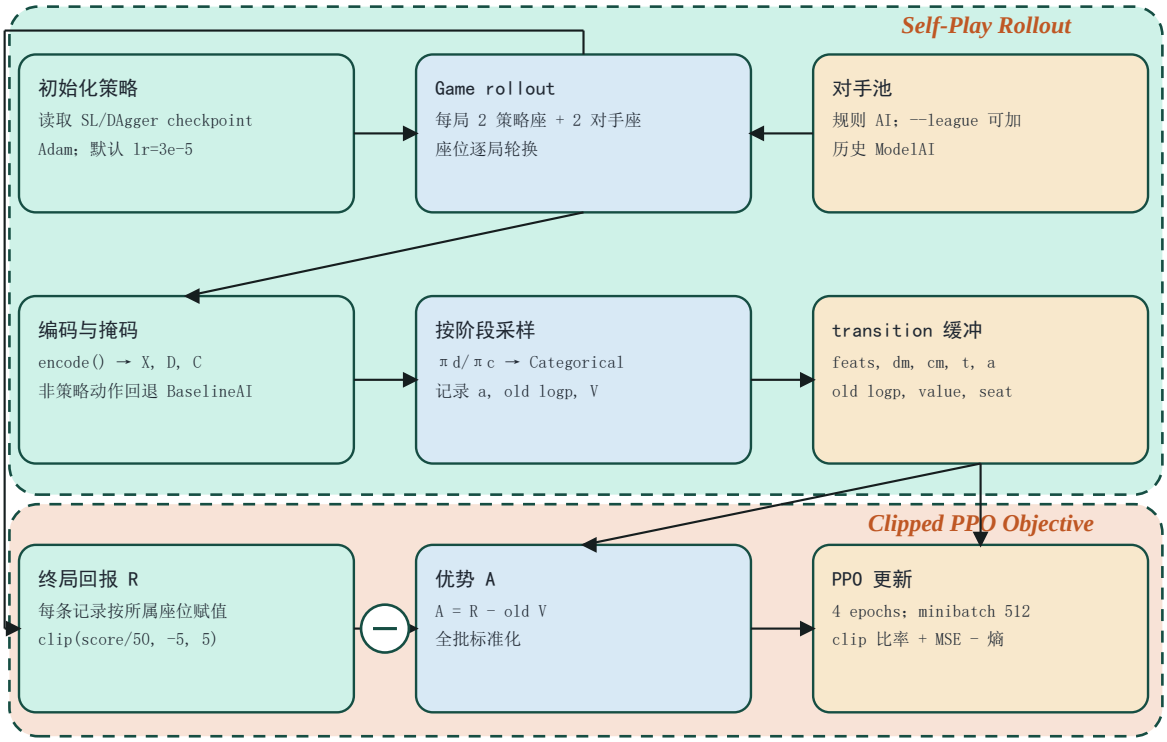
4.1 行为克隆与 DAgger

collect.py 让四个规则 AI 对局，只把出牌决策和至少有两个合法响应的响应决策写入 NPZ；Y 是规则 AI 动作。train_sl.py 先按 G 局号划分训练与验证，再按 T 选择相应动作头。一个 minibatch 的损失为存在的出牌交叉熵 + 存在的响应交叉熵 + 0.5 × MSE(V,R)，其中 R 为该座位终局分/50；使用 Adam，默认 batch=512、lr=3e-4。保存验证总损失最低的权重。

$$L_{BC} = L_{CE,D} + L_{CE,C} + 0.5\, L_{MSE}(V, R) \tag{4-1}$$

dagger.py 每局轮换两个模型座，另外两座由规则专家行动。在模型座的决策点，模型动作推进 Game，规则专家在同一访问状态产生监督标签 Y；因此收集的是模型分布下的专家标签。它保留与 BC 相同的 X/D/C/Y/T/R/G/S 字段，之后显式合并 sl.npz 与 dagger.npz 重新训练。当前实现是一次数据聚合，并非多轮迭代式 DAgger。

4.2 PPO 采样与更新



ratio = exp(new logp - old logp)； ε=0.2，value_coef=0.5，entropy_coef=0.01，梯度裁剪 0.5。

无轨迹折扣、GAE、KL 早停；更新后进入下一轮 rollout，最终保存 ppo_policy.pt。

图 4-2 PPO 的采样、transition 缓冲、优势计算和参数更新

RolloutAgent 只对出牌和响应采样：从相应掩码头建立 Categorical 分布，记录 (X,D,C,T,a,old logp,V,seat)。同局另两座的对手默认是规则 AI，--league 可追加历史模型。每局结束后，把该座位最终得分 / 50 裁剪到 [-5,5]，赋给该座位的所有已记录决策点；没有逐步奖励。

更新时先计算 A = R - V_old，并在整批 transition 上标准化。对每个 minibatch 重新计算 logp_new，取 r = exp(logp_new - logp_old)；策略损失为 -mean(min(rA, clip(r,1-ε,1+ε)A))， ε=0.2。总损失再加 0.5 × MSE(V_new,R)，减 0.01 × 当前动作头的熵；默认训练 4 epoch，minibatch=512，Adam lr=3e-5，梯度范数裁剪 0.5。这里的 A 是终局回报减价值基线，不是 GAE；也没有折扣回报、KL 早停或动态对手池更新。熵项概率保留在计算图中，使熵正则参与策略梯度。

$$R_s = \mathrm{clip}(\mathrm{score}_s/50, -5, 5),\quad A_t = R_{s(t)} - V_{\mathrm{old},t} \tag{4-2}$$

$$r_t = \exp(\log \pi_{\mathrm{new}}(a_t|x_t) - \log \pi_{\mathrm{old}}(a_t|x_t)) \tag{4-3}$$

$$L_{\mathrm{PPO}} = -\mathrm{mean}[\min(rA, \mathrm{clip}(r,0.8,1.2)A)] + 0.5\ \mathrm{MSE}(V,R) - 0.01\ H \tag{4-4}$$

5 实验记录与可解释范围

已有文档记录使用 300 局、每局两模型座对两规则座、按局轮换座位的评测。指标 Δ = 模型座平均分 − 基线座平均分；越接近 0 或转正表示模型越强。以下数值来自 docs/M1_TRAINING.md 与 docs/M2_RL.md 的既有实验记录，本次未重新训练或复跑 300 局评测。

表 5-1 历史评测点估计

策略	记录中的 Δ（分/座）	说明
SL 纯行为克隆	-1.13	5000 局规则 AI 样本
SL + PPO	-0.927	10 × 24 局，旧实验
SL + DAgger	-0.69	额外 600 局专家重标
DAgger + PPO	-1.037	15 × 32 局，带历史对手

在已记录的四组比较里，DAgger 模型的得分差最高；相对 BC 缩小 0.44 分/座。DAgger 后继续 PPO 的结果较差，但这些 300 局点估计没有置信区间，不能据此断言方法本身无效。验证集动作一致率只衡量对规则专家标签的拟合，不等于实战强度。旧稿的学习曲线只有脚本中硬编码的数值，仓库未留原始逐轮日志，因此本版不展示该曲线。

6 复现、限制与后续工作

复现入口：python scripts/run_tests.py；python training/collect_batch.py --games 5000 --shard-size 1000 --out data/sl.npz；python training/train_sl.py --data data/sl.npz --epochs 12；python training/dagger.py --init checkpoints/sl_policy.pt --games 600 --out data/dagger.npz；python training/evaluate.py --checkpoint checkpoints/sl_dagger.pt --games 300。若重训 DAgger 模型，train_sl.py 需显式指定 --data data/sl.npz,data/dagger.npz --out checkpoints/sl_dagger.pt。

主要限制：规则配置尚需按目标玩法核对；PPO 采样量小且没有时序优势估计；评测未报告多种子波动或置信区间；训练脚本的检查点只存模型权重与结构参数，缺少完整实验元数据。服务化、批量推理、灰度发布和房间管理目前停留在设计文档。后续宜先完善评测记录与多种子比较，再扩大采样并调整 PPO，最后处理部署。

依据：仓库 src/sichuan_mahjong/*.py、training/*.py、data/*.npz 的字段/形状，以及 docs/M1_TRAINING.md、docs/M2_RL.md 中的历史实验记录。

后续复现应保存采样命令、随机种子、规则配置、代码版本、数据哈希、训练/验证局号与最优轮次；评测则应留存每局四座得分、座位分配和异常结束标记。当前 NPZ 中保留了 G/S 字段，但检查点缺少完整实验元数据。

附图索引

随正文附有七页 A3 横向矢量附图，可放大查看模块端口与内部结构：A1 总体框架及输入输出；A2 规则状态机与规则策略；A3 404 维编码和动作掩码；A4 三头 MLP 与推理路由；A5 BC 和单轮 DAgger；A6 PPO 采样与更新；A7 2v2 评测。附图的张量形状、动作映射和公式均按当前代码标注。

A1　总体框架与端口联系

实线箭头为运行时数据流；下层虚线组为训练/评测回路。输入形状以单个决策点计。

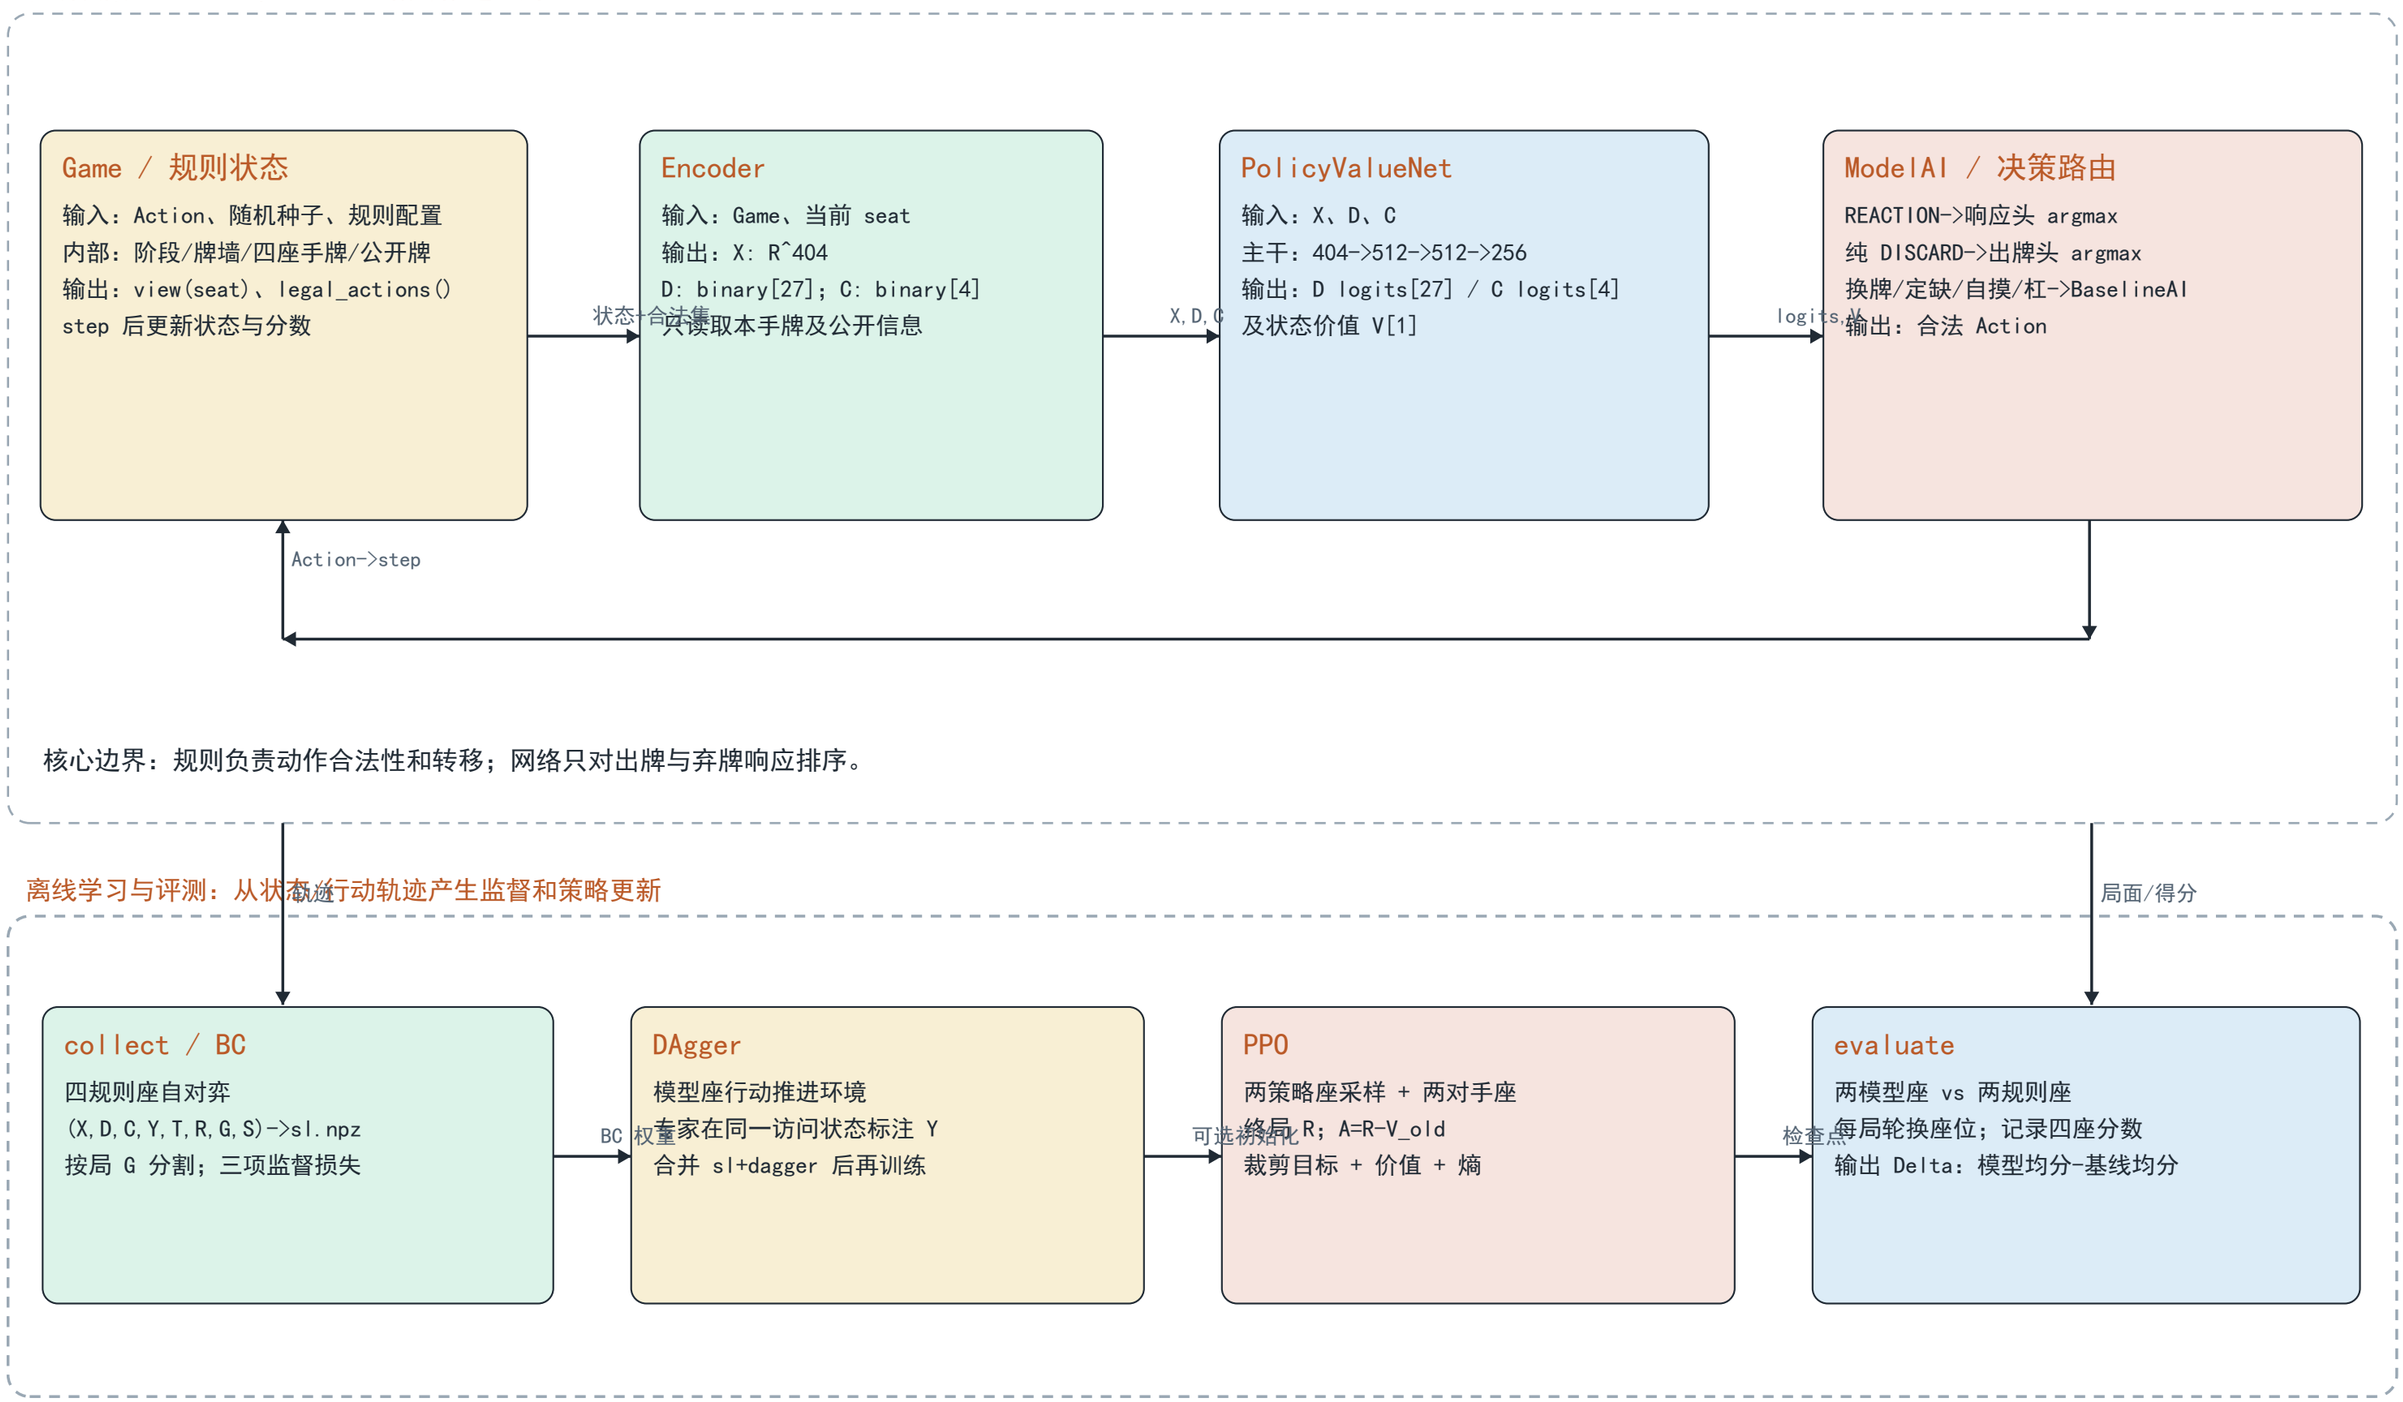


图 A-1 总体框架与端口联系

A2　规则状态机与规则策略内部结构

每个转移由 Game.step(Action) 校验；合法集来自 Game.legal_actions()。抢杠胡是已实现分支。

状态机与响应仲裁

SWAP / 换三张

四座各选三张；按规则方向交换
收齐后进入定缺

MISSING / 定缺

四座声明缺门
收齐后发起摸牌/行动

TURN / 回合

摸牌->可自摸/杠/弃牌
弃牌后建立待响应牌

REACTION / 响应

收集各座合法响应
胡优先；再明杠/碰；否则过

响应处理后继续

特殊终局 / 续打

胡牌座退出；其余座继续。活跃人数、牌墙和流局条件决定 OVER。

TURN 内的抢杠胡分支

补杠触发抢杠窗口时仅允许 HU / PASS；无人胡后完成补杠。

BaselineAI.choose(game, seat, legal_actions) 微观决策

换牌

候选牌连接性排序
选低连接性的三张

定缺

比较各花色手牌强度
选弱门

胡/杠

合法自摸胡、点炮胡优先
可杠时按规则处理

碰

比较碰前后向听数
仅在规则条件满足时碰

弃牌

按向听/连接性/未见张数
及随机平局项排序

各决策支路按当前阶段与合法动作集选用，返回 Action -> Game.step；网络回退也使用同一接口。

图 A-2 规则状态机与规则策略内部结构

A3　404 维状态编码与独立动作掩码

左侧为精确半开区间 [start:end)；特征来自本人可见信息，不读取对手暗牌。

encode_state(game, seat) -> X[404]

[0:27)	本人手牌	count/4
[27:54)	本人碰掩码	0/1
[54:81)	本人杠掩码	0/1
[81:189)	四座弃牌	4x27, count/4
[189:297)	四座明副露牌	4x27, count/4
[297:309)	四座定缺	4x3, one-hot
[309:310)	牌墙剩余	length/55
[310:314)	四座分数	score/50
[314:318)	四座已胡	0/1
[318:345)	本人刚摸牌	27, one-hot
[345:346)	响应阶段标记	0/1
[346:373)	待响应弃牌	27, one-hot
[373:377)	弃牌者相对座位	(discarder-seat)%4
[377:404)	每种牌剩余张数	max(0,4-visible)/4

由 legal_actions() 独立生成

D[27] 出牌掩码

D[t]=1 iff 存在 DISCARD(tile=t)

非法 t 在网络中 masked_fill 为极小值

C[4] 响应掩码

顺序：胡 / 碰 / 明杠 / 过

C[k]=1 iff 对应 kind 在合法集中

阶段与端口

D、C 均不占 X 的 404 维。

剩余张数子图

可见张数 visible[t]

本人手牌 + 四座弃牌 + 四座明副露

remaining[t]

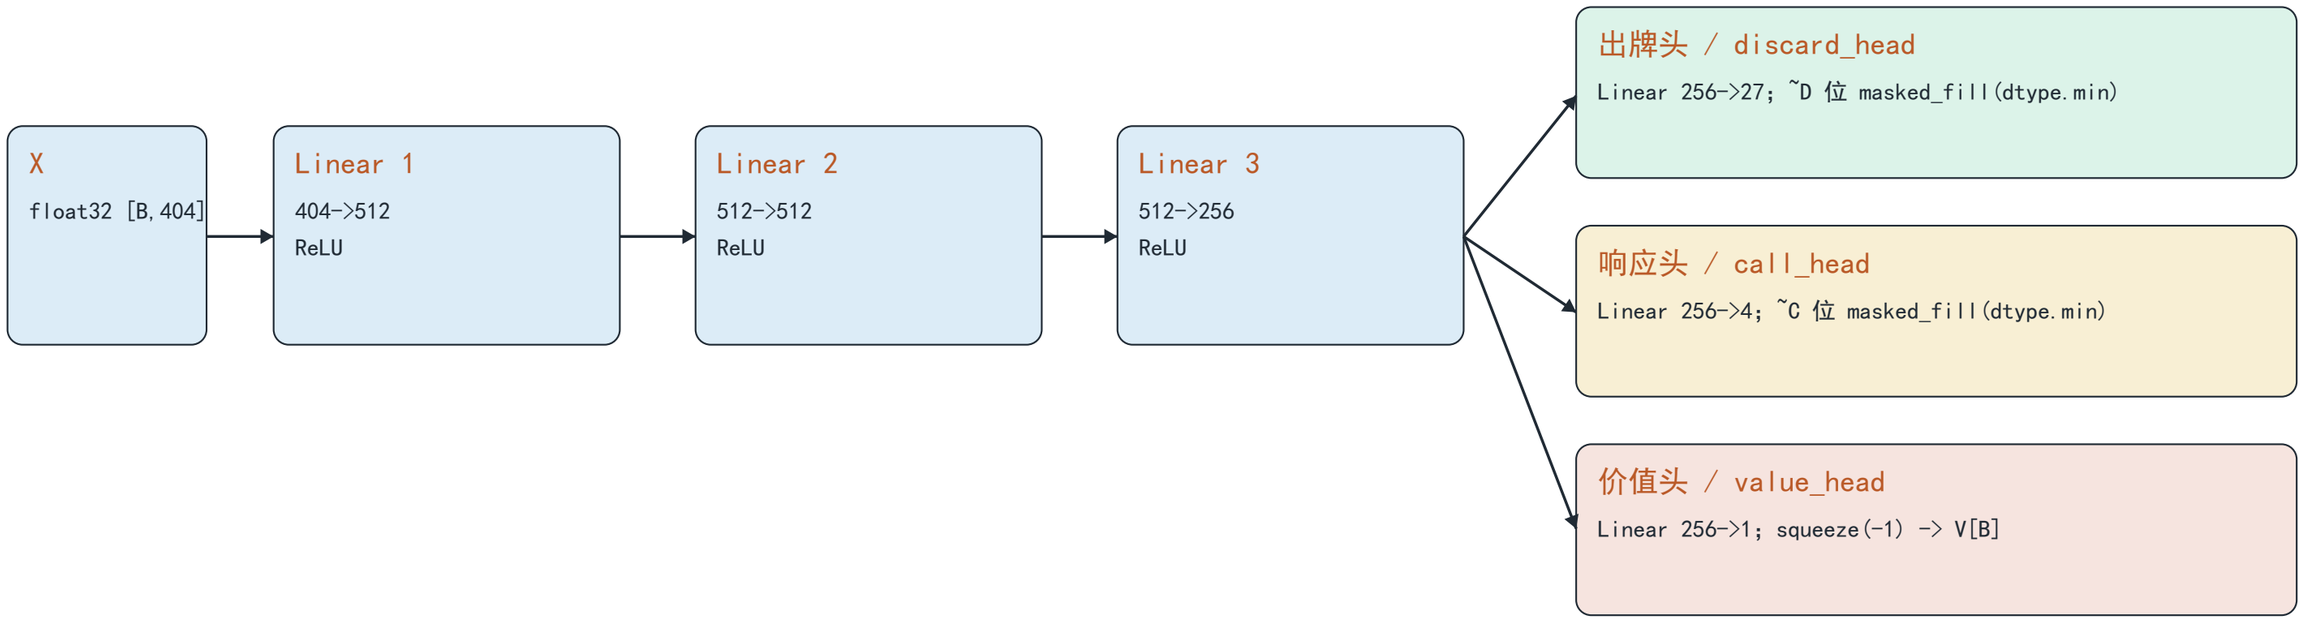
max(0, 4-visible[t]) / 4

图 A-3 404 维状态编码与独立动作掩码

A4　三头 MLP 与 ModelAI 决策路由

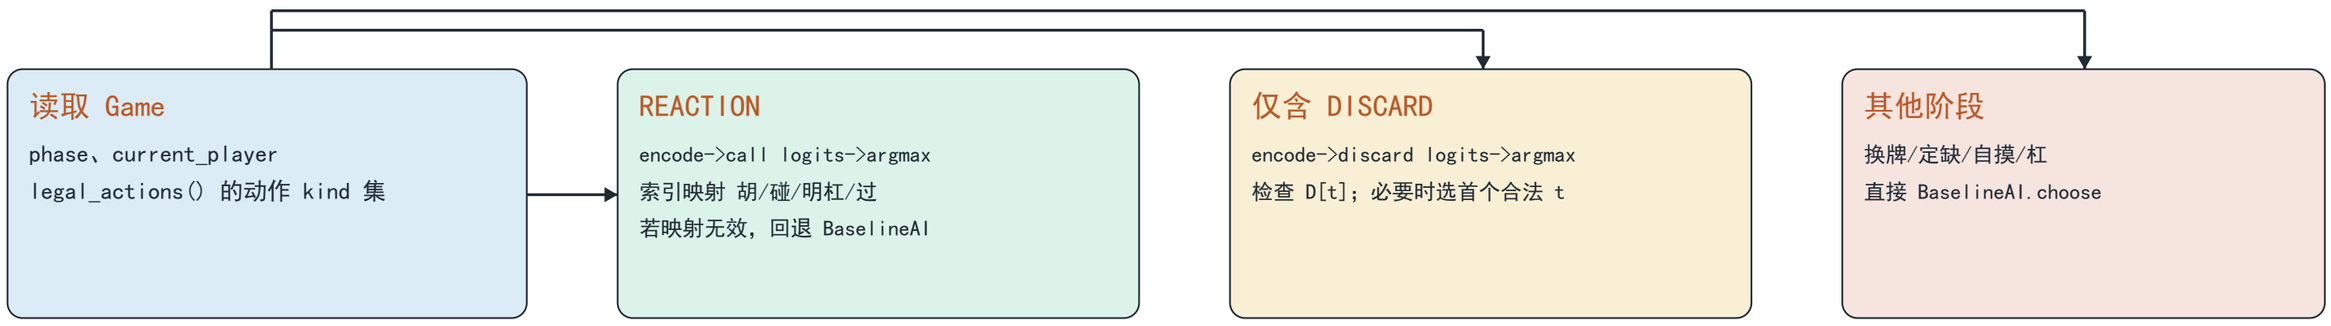
层宽、ReLU、输出和掩码操作均按 model.py / policy_ai.py；当前 hidden=512，总参数 609568。

PolicyValueNet.forward(X,D,C) 的逐层结构



三个头共享 256 维表示；掩码只作用于两个动作 logits，价值头不受掩码影响。

ModelAI.act 路由与输出 Action



三路最终都返回 Action，经 Game.step 校验并推进局面；推理阶段不使用价值头。

图 A-4 三头 MLP 与决策路由

A5　BC 与单轮 DAgger 的微观数据流

监督标签 Y 来自规则专家；模型访问状态上的专家重标是 DAgger 的关键。

规则自对弈收集 -> 行为克隆 BC

四座 BaselineAI

Game 每个决策点产生合法集

仅出牌或 >=2 合法响应入样

专家动作 -> Y；动作类型 -> T

样本字段

X[404],D[27],C[4]

Y,T；终局 R=score/50

G=局号，S=座位；写 sl.npz

按局切分

按 G 分训练 / 验证

相同一局不跨集合

minibatch=512，Adam 3e-4

监督损失与检查点

L=CE_discard (T=0)+CE_call (T=1)

+0.5xMSE(V,R)；只计算存在的类型

保存验证总损失最低的权重

说明：响应样本过滤掉只有一个合法响应的决策点；R 在终局后回填至本座该局样本。

模型分布访问状态 -> 专家重标 -> 合并再训练

模型座轮换

每局两模型座、两专家座

ModelAI 的动作推进 Game

同状态专家查询

在模型访问的同一局面

BaselineAI 给出标签 Y

不以专家动作推进模型座

新增样本

X,D,C,Y,T,R,G,S

写 dagger.npz

当前实现仅一次聚合

聚合与再训练

sl.npz + dagger.npz 显式合并

重新按 G 切分；同一监督目标

输出 DAgger 检查点

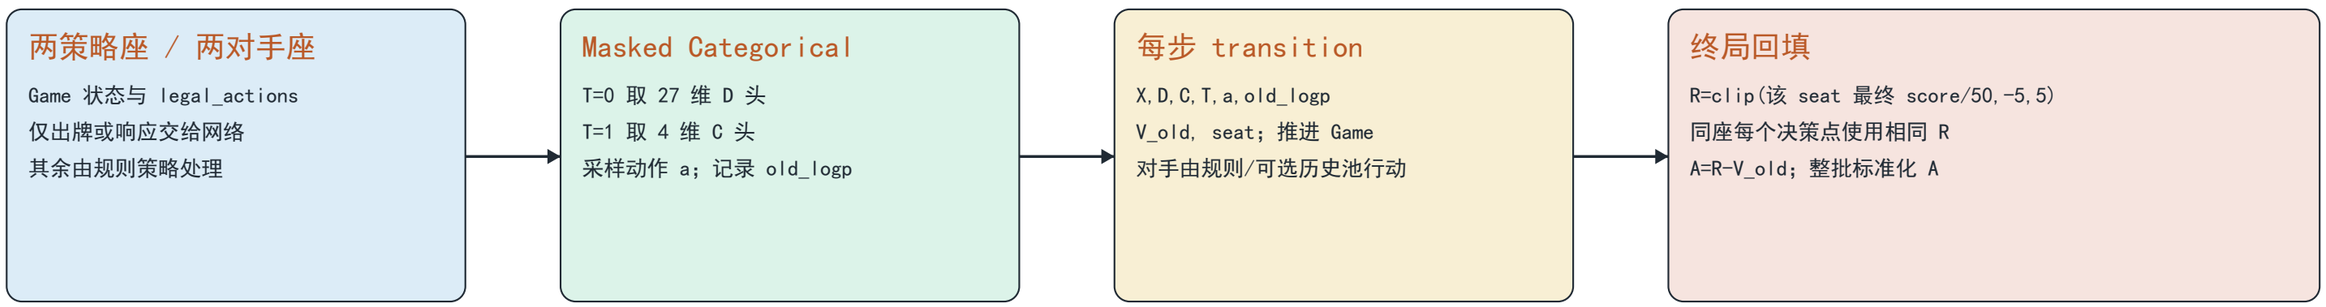
DAgger 的数据分布来自模型实际行动；标签仍由规则专家产生。

图 A-5 BC 与单轮 DAgger 数据流

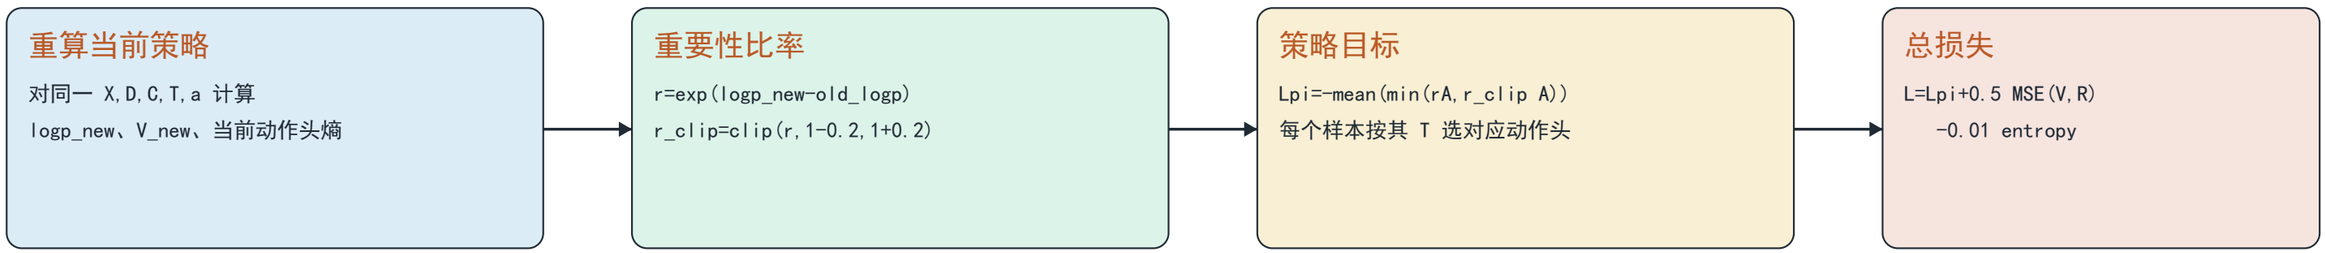
A6　PPO 采样、优势与裁剪更新

按当前 ppo.py：终局座位得分回填、无 GAE；熵正则保留梯度。

rollout：模型座策略采样 -> transition 缓冲



update：4 epoch x minibatch 512；Adam lr=3e-5，梯度裁剪 0.5



实现边界：无折扣回报、GAE、KL 早停或动态对手池更新；熵项概率保留梯度。

图 A-6 PPO 采样与裁剪更新

A7　评测模块与得分指标

evaluate.py 的单位是“分/模型座”；历史表格数值是既有记录，本图展示当前评测算法。

逐局 2v2 座位轮换、动作执行与分数汇总

局 k / 随机种子

创建 Game(seed+k)

s0=k%4

模型座={s0,(s0+1)%4}

另外两座=规则 AI

各决策点

当前座选相应 ModelAI/BaselineAI

agent.act(game)->Action

Game.step；结束或步数>5000 停止

单局结算

获取四座 score

累加 model_score

累加 base_score

跨局汇总

games=N

模型/基线各 2N 座

计算 Delta

指标定义

Delta = (Sum模型座分数 - Sum规则座分数) / (2N)

每局换位减少固定座位偏差；正值表示模型座平均分高于基线座。

可复现记录应包含：每局 seed、四座身份及得分、规则配置、检查点、代码版本。

本次报告的结果证据范围

既有实验文档只保留 300 局的点估计，未保存逐局明细；不能从现有资料计算置信区间。

该指标评估整套“网络决策 + BaselineAI 回退 + 规则引擎”的对局表现，而非孤立网络层的质量。

图 A-7 评测模块与得分指标